REPUBLIQUE DEMOCRATIQUE DU CONGO

ENSEIGNEMENT SUPERIEUR ET UNIVERSITAIRE

INSTITUT SUPERIEUR DE STATISTIQUE

ECOLE DOCTORALE DE STATISTIQUE ET INFORMATIQUE (EDSI)

B. P. 2471

LUBUMBASHI

TRAVAIL PRATIQUE DU COURS DE DATA MINING

Titulaire du Cours : MBAKI LUZAYISU Efrem

Présenté par :

- PINTO KATENDE Jonathan
- MUSONDA Balthazar
- KHANG MATE ZULBAL
- MUKWIYO MUKALO Patrick
- MPUNDU MWANA NGOY

2024

QUESTION

Objectif

1. **Préparation des Données :**
    - Importer les données et vérifier s'il y a des valeurs manquantes.
    - Nettoyer les données en traitant les valeurs manquantes et en codant les variables catégorielles si nécessaire.
2. **Analyse Exploratoire :**
    - Calculer les statistiques descriptives pour chaque variable et visualiser la répartition des variables
        - Statistique univariée
        - Statistique Bivariée
        - Etude des liaisons et corrélations
3. **Modélisation :**
    - Construire un modèle pour prédire les différentes Catégories en fonction des autres variables
    - Évaluer la performance du modèle.
4. **Visualisation et Interprétation :**
    - Présenter les résultats de manière visuelle (graphes, diagrammes).
    - Interpréter les résultats et proposer des recommandations

ANALYSE

Dans le cadre de cette analyse, nous utilisons Python 3.13 comme langage de programmation.

Voici les librairies qui serons utilisés :

Préparation des données

Installation des packages

```
%pip install pandas numpy # Manipulation excel
%pip install --upgrade pip # Gestionnaire des paquets
%pip install polars # Meilleur alternatif de Pandas
%pip install matplotlib plotly # Pour la visualisation
%pip install fastexcel # Dépendance de Polars pour le fichie .xlsx
%pip install pyarrow # Dépendance de Polars pour le fichie .xlsx
%pip install openpyxl # Dépendance de Polars pour le fichie .xlsx
%pip install seaborn # Pour la visualisation
%pip install scikit-learn # Pour la visualisation
%pip install statsmodels # Pour la visualisation
%pip install plotnine # Pour la visualisation
%pip install tabulate colorama # Pour la colaration
```

Chargement des packages

```
import pandas as pd # type: ignore
import numpy as np
import polars as pl
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, classification_report
from sklearn.preprocessing import LabelEncoder
import statsmodels.api as sm
from statsmodels.stats.outliers_influence import
variance_inflation_factor
from plotnine import * # type: ignore  # noqa: F403
import scipy.stats as ss
from tabulate import tabulate
from colorama import Fore, Style, Back
```

Importation des données

```
data_pl = pl.read_excel("data.xlsx") # Pour la manipulation avec Polars
data_pd = pd.read_excel("data.xlsx") # Pour la manipulation avec Pandas
ctx = pl.SQLContext(data=data_pl, eager=True) # Ecriture en SQL
```

Illustration des données

```
print(data_pl)
```

shape: (5_744, 19)

CATEGORIE	GRADE	DERNIER AVACEMENT EN GRADE	SALAIRE PERS	…	ENERGIE	IFT	IDP	IPM
str	str	date	f64		i64	f64	f64	i64
M&C	11	1998-07-01	47865.44225	…	12045	97837.51	126115.18	348500
M&C	11	1998-09-01	47652.18334	…	12045	97837.51	126115.18	348500
M&C	11	2000-08-01	47348.71096	…	12045	97837.51	126115.18	348500
M&C	11	2000-10-01	47115.68266	…	12045	97837.51	126115.18	348500
M&C	11	2000-12-01	47344.56758	…	12045	97837.51	126115.18	348500
…	…	…	…	…	…	…	…	…
EXE	71	2023-11-01	4920.44077	…	5940	67568.84	46635.93	342500
EXE	71	2023-11-01	4920.44077	…	5940	67568.84	46635.93	342500
EXE	71	2023-11-01	4920.44077	…	5940	67568.84	46635.93	342500
EXE	61	2023-11-01	4913.62077	…	5940	67278.84	46413.51	342500
EXE	61	2023-11-01	4913.62077	…	5940	67278.84	46413.51	342500

Explication des variables

- **CATEGORIE** : Code ou description de la catégorie professionnelle du personnel
- **GRADE** : Niveau de grade de l'employé au sein de la catégorie
- **DERNIER AVACEMENT EN GRADE** : Date du dernier avancement en grade de l'employé.
- **SALAIRE PERS** : Salaire personnel ou de base de l'employé,
- **CITE** : Code de la cité ou de la localité où réside l'employé
- **SEXE** : Sexe de l'employé
- **ETATCIVIL** : Code de l'état civil de l'employé.
- **INDEPOUSE** : Indicateur pour savoir si l'employé a un conjoint à charge. Par exemple, "1" pour oui et "0" pour non.
- **ENFANT** : Nombre d'enfants à charge de l'employé
- **COTATION** : Code de cotation ou score lié au poste ou à la performance de l'employé.
- **DATENAISSA** : Date de naissance de l'employé.
- **DATEENGAGE** : Date d'engagement de l'employé dans l'entreprise (date d'embauche).
- **TRP** : Indemnité de transport, ou allocation liée aux frais de déplacement.
- **LGT** : Allocation logement de l'employé.
- **SSANTE** : Cotisation ou indemnité pour la sécurité sociale ou assurance santé.
- **ENERGIE** : Allocation ou indemnité énergétique, qui pourrait couvrir des frais d'électricité, de chauffage, etc.
- **IFT** : Allocation ou indemnité pour frais de téléphone.
- **IDP** : Indemnité pour dépendants, ou allocation pour les personnes à charge.
- **IPM** : Indemnité pour prestations médicales, couvrant potentiellement les frais de santé ou d'hospitalisation.

Information sur les variables

```
print(data_pd.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5744 entries, 0 to 5743
Data columns (total 19 columns):
 #   Column                      Non-Null Count  Dtype
---  ------                      --------------  -----
 0   CATEGORIE                   5744 non-null   object
 1   GRADE                       5744 non-null   int64
 2   DERNIER AVACEMENT EN GRADE  5742 non-null   datetime64[ns]
 3   SALAIRE PERS                5744 non-null   float64
 4   CITE                        5744 non-null   object
 5   SEXE                        5744 non-null   object
 6   ETATCIVIL                   5678 non-null   object
 7   INDEPOUSE                   5534 non-null   float64
 8   ENFANT                      5744 non-null   int64
 9   COTATION                    2536 non-null   float64
 10  DATENAISSA                  5744 non-null   datetime64[ns]
 11  DATEENGAGE                  5744 non-null   datetime64[ns]
 12  TRP                         5744 non-null   float64
 13  LGT                         5744 non-null   float64
 14  SSANTE                      5744 non-null   float64
 15  ENERGIE                     5744 non-null   int64
 16  IFT                         5744 non-null   float64
 17  IDP                         5744 non-null   float64
 18  IPM                         5744 non-null   int64
dtypes: datetime64[ns](3), float64(8), int64(4), object(4)
memory usage: 852.8+ KB
```

Nous constatons que l'analyse est faite sur 5744 individus.

Sur toutes les variables, nous remarquons que la variable **COTATION** a près de 50% des valeurs manquantes. En plus, cette variable cotation n'intéresse que ceux de la catégorie M&C. D'où, elle sera supprimée lors de la modélisation.

Création des variables artificielles

En se fiant sur les données que nous disposons, nous constatons que certaines variables artificielles peuvent être créées :

- **L'âge à l'engagement** : la différence entre la date d'engagement et la date de Naissance.
- Après que l'âge à l'engagement soit créé, une autre variable peut être créée sur la base de celle-ci : **tranche d'âge.**

  Pour la création des classes, il existe des critères et des méthodes existent du point de vu statistique, entres autres :

  - Méthode de LIORZOU
  - Méthode de Stem and Leaf

  Dans le cadre de cette étude, nous allons nous limiter par une méthode manuelle d'amplitude 5, de la valeur minimale de cette variable jusqu'à sa valeur maximale.

Création de variable âge

```
result = data_pl.select(
    pl.col('DATENAISSA'),
    pl.col('DATEENGAGE'),
    ((pl.col("DATEENGAGE") - pl.col('DATENAISSA')).cast(pl.Duration) / pl.
duration(days=365.25)).cast(pl.Int32).alias("Age à l'engagement")
)

print(result)
```

Voici comment se présente cette nouvelle variable :

```
shape: (5_744, 3)
┌─────────────┬─────────────┬──────────────────────┐
│ DATENAISSA  ┆ DATEENGAGE  ┆ Age à l'engagement   │
│ ---         ┆ ---         ┆ ---                  │
│ date        ┆ date        ┆ i32                  │
╞═════════════╪═════════════╪══════════════════════╡
│ 1950-06-02  ┆ 1968-09-01  ┆ 18                   │
│ 1954-01-01  ┆ 1980-04-14  ┆ 26                   │
│ 1960-02-02  ┆ 1987-12-14  ┆ 27                   │
│ 1953-01-15  ┆ 1977-08-15  ┆ 24                   │
│ 1963-05-24  ┆ 1987-12-14  ┆ 24                   │
│ …           ┆ …           ┆ …                    │
│ 1990-05-15  ┆ 2023-11-01  ┆ 33                   │
│ 2000-05-05  ┆ 2023-11-01  ┆ 23                   │
│ 1997-04-12  ┆ 2023-11-01  ┆ 26                   │
│ 1988-02-06  ┆ 2023-11-01  ┆ 35                   │
│ 1991-04-18  ┆ 2023-11-01  ┆ 32                   │
└─────────────┴─────────────┴──────────────────────┘
```

Création de variable Tranche d'âge

```
data_pd = data_pl_new.to_pandas()

bins = [13, 18, 23, 28, 33, 38, 43, 48, 53, 56]
labels = ['13-18', '18-23', '23-28', '28-33', '33-38', '38-43', '43-48',
'48-53', 'Plus de 53']
data_pd['tranche_age_engagement'] = pd.cut(data_pd['age_engagement'],
bins=bins, labels=labels, right=False)

print(data_pd[['age_engagement', 'tranche_age_engagement']])
```

```
      age_engagement tranche_age_engagement
0                 18                  18-23
1                 26                  23-28
2                 27                  23-28
3                 24                  23-28
4                 24                  23-28
...              ...                    ...
5739              33                  33-38
5740              23                  23-28
5741              26                  23-28
5742              35                  33-38
5743              32                  28-33

[5744 rows x 2 columns]
```

Analyse exploratoire

Dans le cadre de cette analyse, nous considérons la variable CATEGORIE comme variable cible.

- **Analyse univariée**

Variables Quantitatives

```
print(data_pl_new.select(
    pl.col('age_engagement'),
    pl.col('SALAIRE PERS'),
    pl.col('ENFANT')
).describe())
```

```
shape: (9, 4)
```

statistic	age_engagement	SALAIRE PERS	ENFANT
str	f64	f64	f64
count	5744.0	5744.0	5744.0
null_count	0.0	0.0	0.0
mean	25.584436	25926.253361	2.184018
std	5.77386	23616.887196	2.524423
min	13.0	4705.46265	0.0
25%	21.0	5180.02077	0.0
50%	24.0	5352.96077	1.0
75%	29.0	49967.96363	4.0
max	55.0	74226.169	16.0

Les résultats de l'analyse montrent que :

- Le salaire moyen de cette population est de 25926
- Tandis que près de 50% des individus de cette population ont un salaire de moins de 5180.
- Se basant sur le nombre d'enfants, en moyenne chaque agent a 2 enfants.
- Près de 50% des agents ne dépasse pas un agent.
- Mais dans cette population, il y a au moins un agent qui a 16 enfants.
- Se référant sur l'âge à l'engagement, on constate que l'âge moyen à l'engagement est de 25 ans.
- Près de 75% d'agents avait moins de 29 ans à l'engagement.

Nous constatons également des incohérences sur plusieures résultats, mais il y a une raison à cela qui pourrait être déceler lors de l'analyse bivariée.

Mais également il y a des résultats qui violent les recommandations de l'Etat Congolais :

Nous voyons que l'âge à l'engagement minimal est de 13 ans, or la loi N°16.010 du 15 Juillet 2016 portant code de la famille stipule que « Tout enfant né en République Démocratique du Congo peut être engagé ou maintenue en service pour l'exécution des travaux légers et salubres, que celui qui 16 à moins de 18 ans ». D'où l'âge minimal pour le travail est de 16 ans.

```
data_pl_new.filter(pl.col('age_engagement') < 16).height
```

```
5
```

On sait voir que l'entreprise a engagé 5 personnes qui ont moins de 16, ce qui est illégal.

Variables Qualitatives

1. Tranche d'âge

```
# Conversion du DataFrame Polars à Pandas
tranche_counts_pd = tranche_counts_pl.to_pandas()

plot = (
    ggplot(tranche_counts_pd, aes(x='tranche_age_engagement',
y='effectif', fill='tranche_age_engagement'))
    + geom_bar(stat='identity', show_legend=False)  # On désactive la
légende ici pour simplifier
    + scale_fill_manual(values=[
        '#1f77b4',  # bleu
        '#ff7f0e',  # orange
        '#2ca02c',  # vert
        '#d62728',  # rouge
        '#9467bd',  # violet
        '#8c564b',  # brun
        '#e377c2',  # rose
        '#7f7f7f',  # gris
        '#bcbd22'   # jaune-vert
    ])
    + labs(
        title='Distribution des employés par tranche d\'âge',
        x='Tranche d\'âge',
        y='Nombre de personnes'
    )
    + theme_minimal()
    + theme(
        axis_text_x=element_text(rotation=45, hjust=1),
        text=element_text(size=12),
        plot_title=element_text(weight='bold', size=14)
    )
)

plot
```

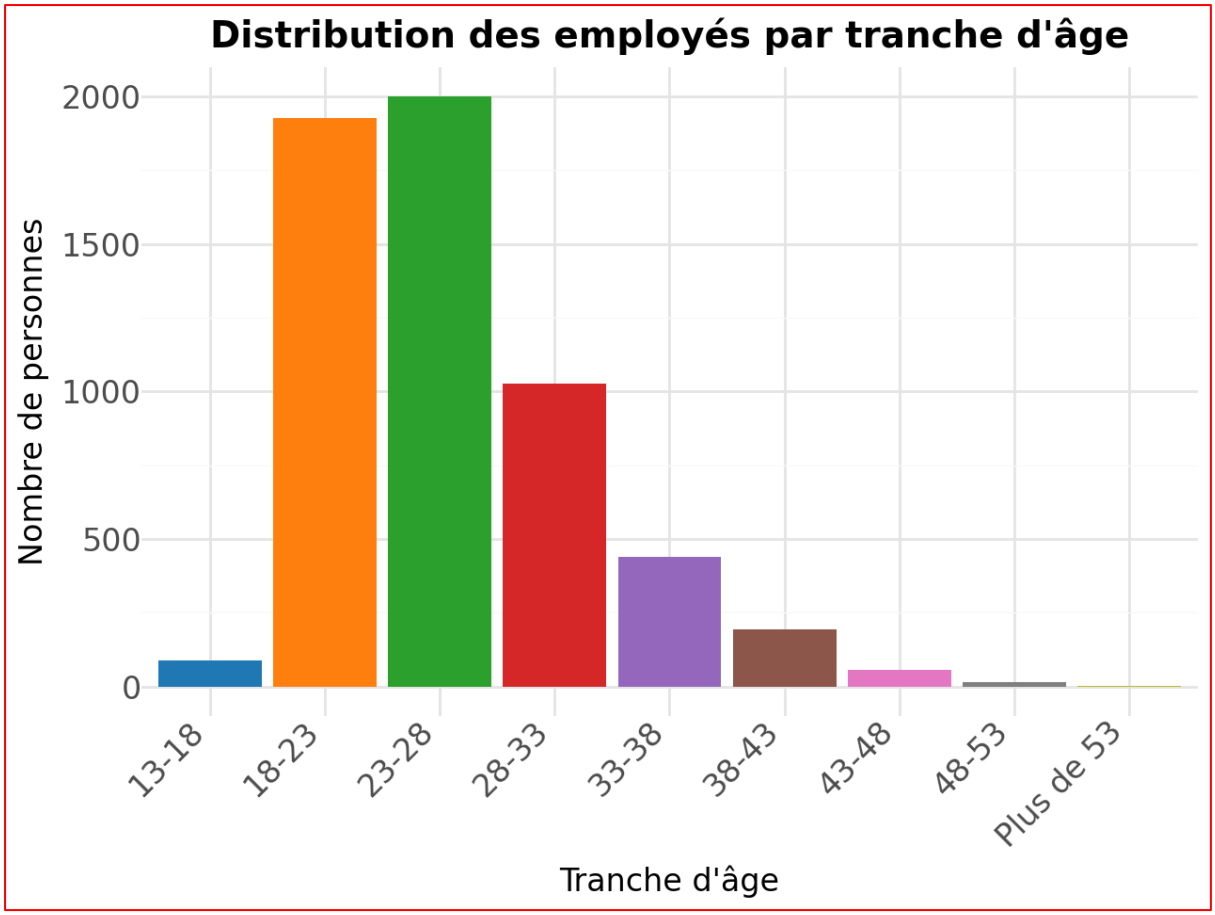

Les résultats montrent que :

- La tranche d'âge majoritaire pour les engagements est de 18 à 38 ans
- Mais avec des engagements aussi entre 13 et 18 ans

2. Catégorie

```
categorie_counts = data_pd[['CATEGORIE']].value_counts().reset_index()
categorie_counts.columns = ['CATEGORIE', 'count']

total_count = categorie_counts['count'].sum()
categorie_counts['percentage'] = (categorie_counts['count'] /
total_count) * 100

(ggplot(categorie_counts, aes(x='CATEGORIE', y='percentage',
fill='CATEGORIE'))
+ geom_bar(stat='identity', show_legend=False)
+ labs(
    title='Distribution par CATEGORIE',
    x='Catégorie',
    y='Pourcentage'
)
+ theme_minimal()
)
```

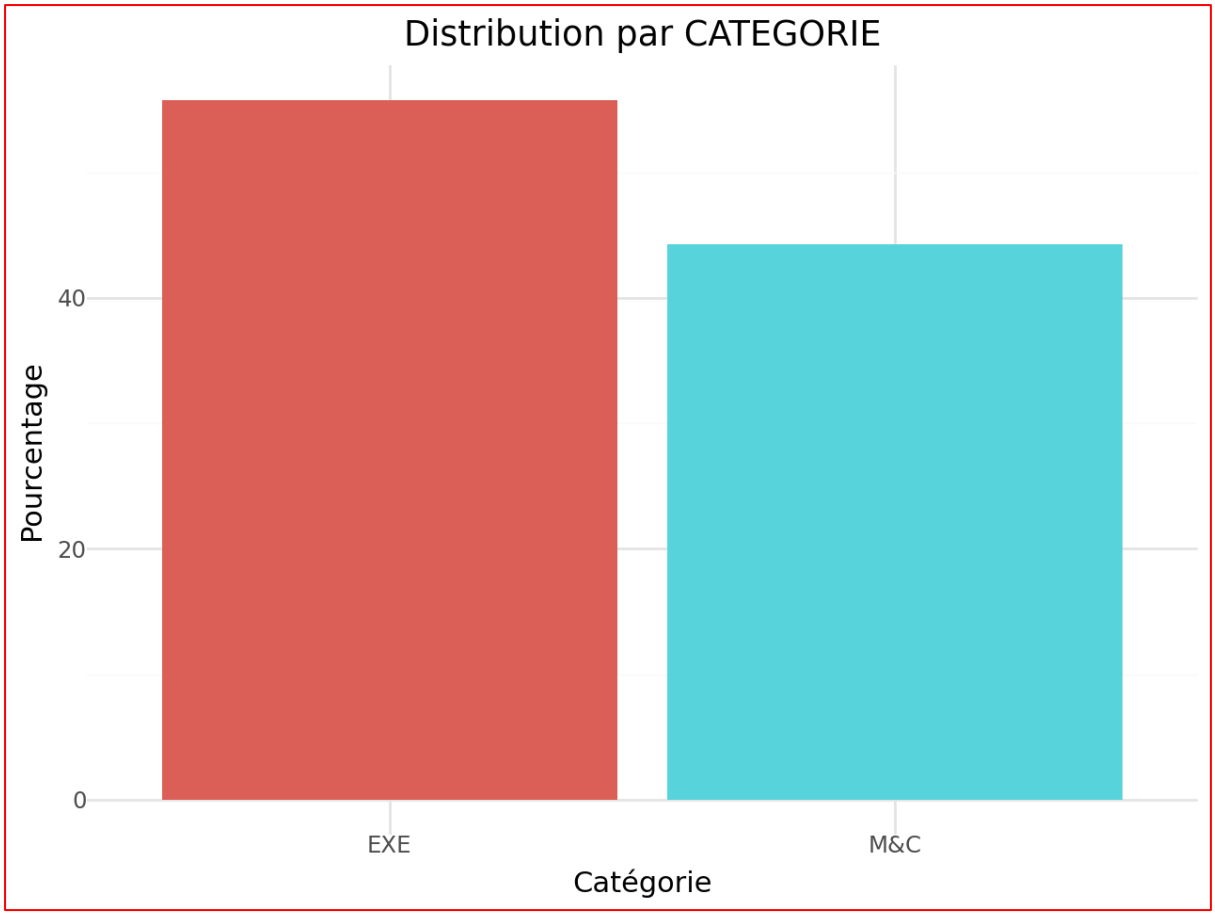

Ce graphique montre que pour cette société, la majorité des employés sont dans la categorie EXE, à hauteur de plus de 55% des agents se trouvant dans cette catégorie.

3. Indepouse (Indicateur pour savoir si l'employé a un conjoint à charge)

```
indepouse_counts = data_pd[['INDEPOUSE']].value_counts().reset_index()
indepouse_counts.columns = ['INDEPOUSE', 'count']

# Calcul des pourcentages
total_count = indepouse_counts['count'].sum()
indepouse_counts['percentage'] = (indepouse_counts['count'] /
total_count) * 100

(
    ggplot(indepouse_counts, aes(x='INDEPOUSE', y='percentage',
fill='factor(INDEPOUSE)'))
    + geom_bar(stat='identity')
    + scale_fill_manual(values=['#66c2a5', '#fc8d62'])  # Palette de
couleurs attrayantes
    + labs(
        title='Distribution des valeurs de INDEPOUSE en pourcentage',
        x='INDEPOUSE',
        y='Pourcentage'
    )
    + theme_minimal()
```

```
    + theme(
        axis_text_x=element_text(rotation=0, hjust=0.5),
        text=element_text(size=12),
        plot_title=element_text(weight='bold', size=14)
    )
)
```

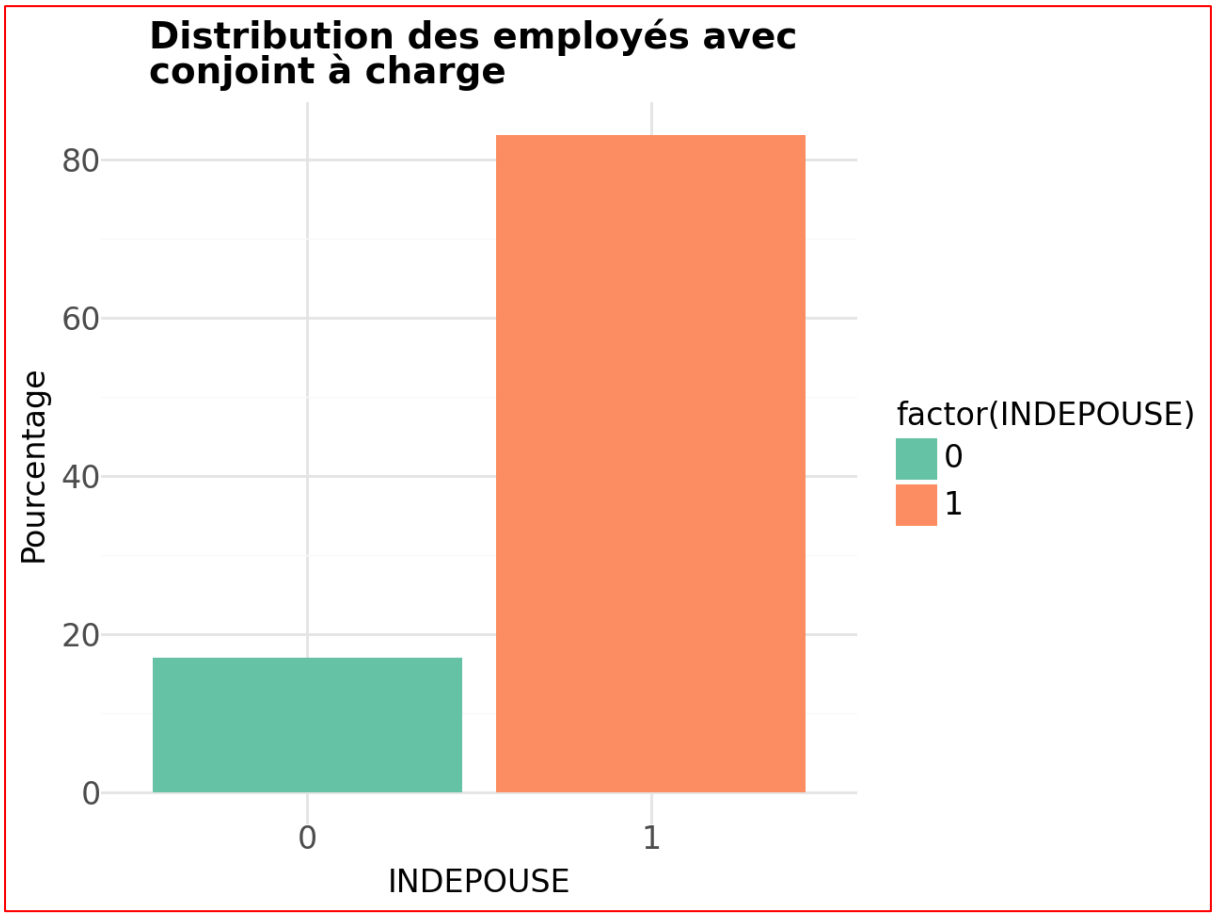

Ce graphique montre que plus de 80% des employés ont un conjoint à charge.

4. Sexe

```
# Conversion des données en DataFrame
sexe_counts = data_pd['SEXE'].value_counts().reset_index()
sexe_counts.columns = ['SEXE', 'count']

# Calcul des pourcentages
total_count = sexe_counts['count'].sum()
sexe_counts['percentage'] = (sexe_counts['count'] / total_count) * 100

(
    ggplot(sexe_counts, aes(x='SEXE', y='percentage',
fill='factor(SEXE)'))
    + geom_bar(stat='identity')
    + scale_fill_manual(values=['#a6cee3', '#b2df8a'])  # Palette de
couleurs attrayantes
```

```
    + labs(
        title='Distribution des employés par SEXE',
        x='SEXE',
        y='Pourcentage'
    )
    + theme_minimal()
    + theme(
        axis_text_x=element_text(rotation=0, hjust=0.5),
        text=element_text(size=12),
        plot_title=element_text(weight='bold', size=14)
    )
)
```

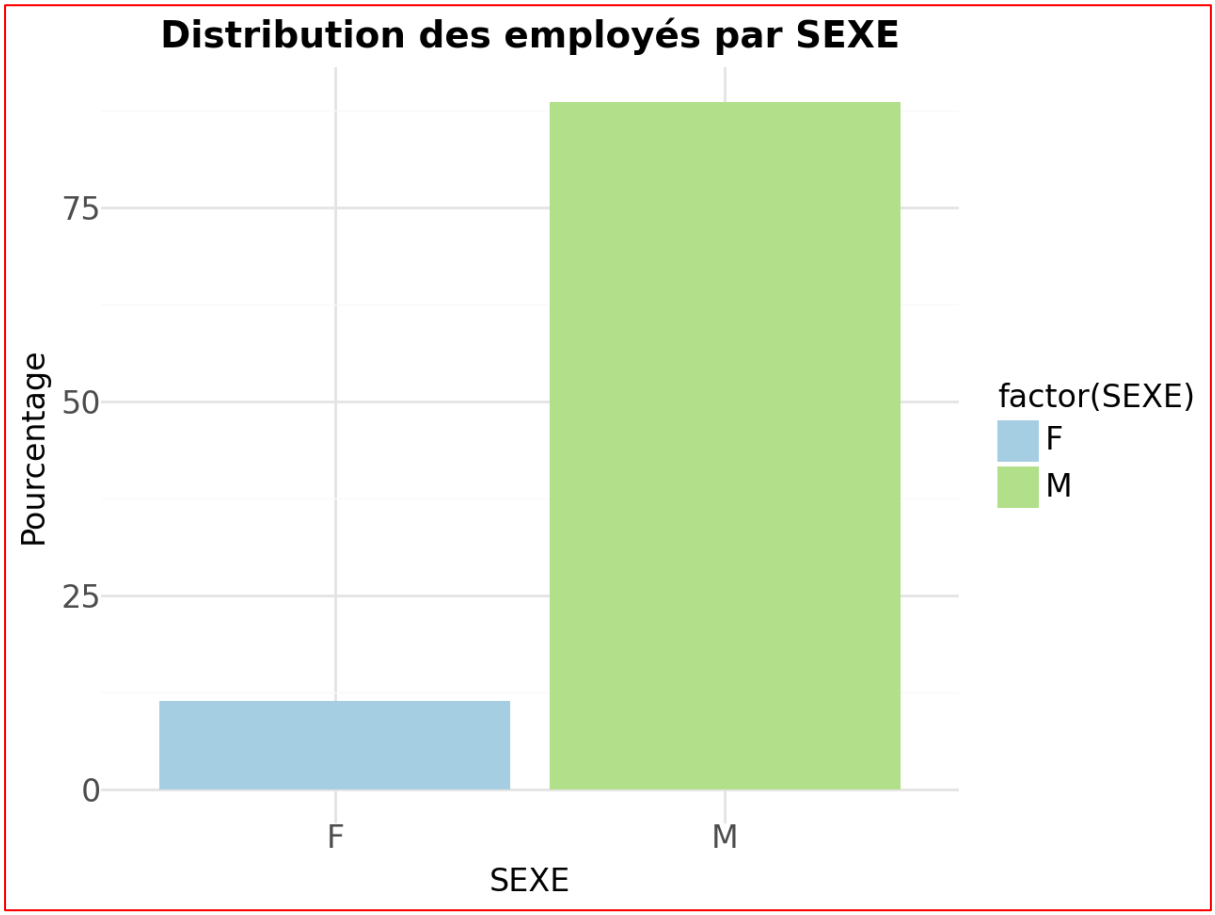

Se basant sur le sexe, plus de 85% des employés sont des hommes. Ce qui montre une prédominance des hommes dans cette entreprise.

- **Analyse bivariée**

Categorie vs Sexe

```
contingency_table = pd.crosstab(data_pd['CATEGORIE'],
data_pd['SEXE']).reset_index()
contingency_table = pd.melt(contingency_table, id_vars='CATEGORIE',
var_name='SEXE', value_name='count')

(
    ggplot(contingency_table, aes(x='CATEGORIE', y='count', fill='SEXE'))
    + geom_bar(stat='identity', position='stack')
    + scale_fill_manual(values=['#febd01', '#0db2a2'])
    + labs(
        title='Répartition des employés selon leur CATEGORIE par SEXE',
        x='Catégorie',
        y='Effectif',
        fill='SEXE'
    )
    + theme_minimal()
    + theme(
        axis_text_x=element_text(rotation=45, hjust=1),
        text=element_text(size=12),
        plot_title=element_text(weight='bold', size=14)
    )
)
```

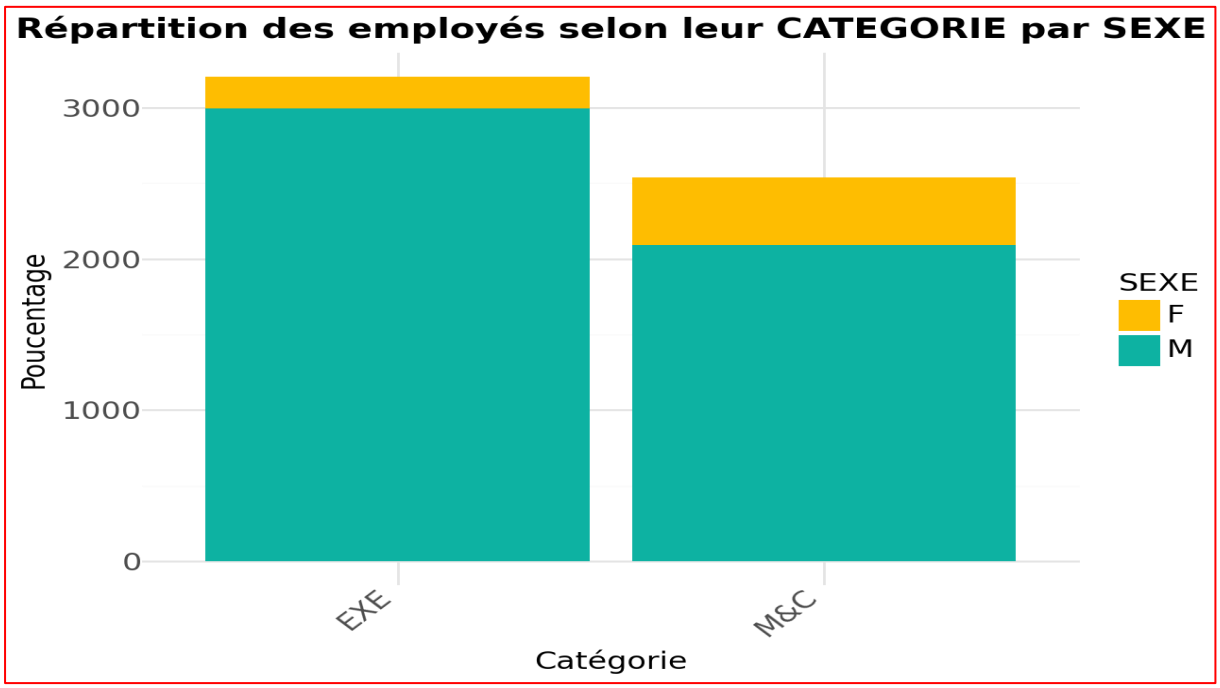

Nous remarquons que dans toutes les catégories confondues, les hommes sont prédominant en termes d'effectif.

Categorie vs Salaire

```
statistiques_salaire = data_pl.group_by("CATEGORIE").agg([
    pl.col("SALAIRE PERS").count().alias("count"),
    pl.col("SALAIRE PERS").mean().alias("mean"),
    pl.col("SALAIRE PERS").std().alias("std"),
    pl.col("SALAIRE PERS").min().alias("min"),
    pl.col("SALAIRE PERS").quantile(0.25).alias("25%"),
    pl.col("SALAIRE PERS").median().alias("50%"),
    pl.col("SALAIRE PERS").quantile(0.75).alias("75%"),
    pl.col("SALAIRE PERS").max().alias("max")
])

print(statistiques_salaire)
```

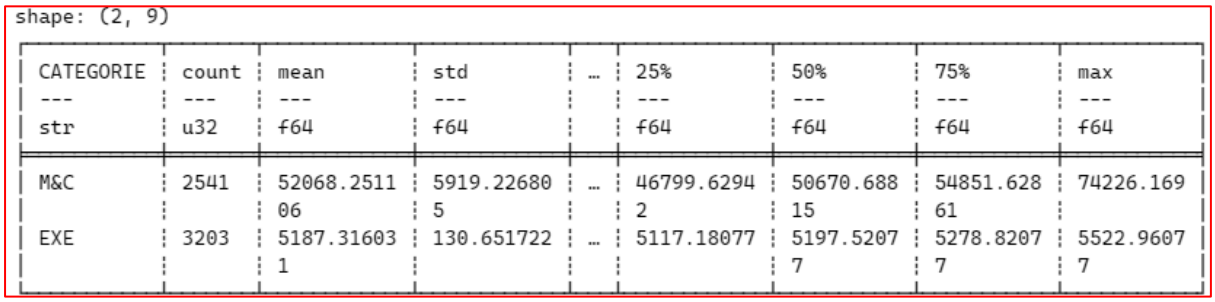

```
shape: (2, 9)
┌──────────┬───────┬─────────────┬─────────────┬───┬─────────────┬─────────────┬─────────────┬─────────────┐
│ CATEGORIE ┆ count ┆ mean        ┆ std         ┆ … ┆ 25%         ┆ 50%         ┆ 75%         ┆ max         │
│ ---      ┆ ---   ┆ ---         ┆ ---         ┆   ┆ ---         ┆ ---         ┆ ---         ┆ ---         │
│ str      ┆ u32   ┆ f64         ┆ f64         ┆   ┆ f64         ┆ f64         ┆ f64         ┆ f64         │
╞══════════╪═══════╪═════════════╪═════════════╪═══╪═════════════╪═════════════╪═════════════╪═════════════╡
│ M&C      ┆ 2541  ┆ 52068.2511  ┆ 5919.22680  ┆ … ┆ 46799.6294  ┆ 50670.688   ┆ 54851.628   ┆ 74226.169   │
│          ┆       ┆ 06          ┆ 5           ┆   ┆ 2           ┆ 15          ┆ 61          ┆             │
│ EXE      ┆ 3203  ┆ 5187.31603  ┆ 130.651722  ┆ … ┆ 5117.18077  ┆ 5197.5207   ┆ 5278.8207   ┆ 5522.9607   │
│          ┆       ┆ 1           ┆             ┆   ┆             ┆ 7           ┆ 7           ┆ 7           │
└──────────┴───────┴─────────────┴─────────────┴───┴─────────────┴─────────────┴─────────────┴─────────────┘
```

De ce résultat, on peut voir :

- Le salaire moyen de la catégorie M&C est de 52068.25F, tandis que dans la catégorie EXE le salaire moyen est de 5187.31F ; ce qui largement inférieur à celle de la catégorie M&C.
- Près de 50% des employés dans la catégorie M&C ne dépassent pas le salaire de 50671 ; de même pour ceux qui sont dans la catégorie EXE, ils ne dépassent pas le salaire 5198.

Categorie vs Nombre d'enfant

```
result = (
    data_pl_new.group_by('CATEGORIE')
    .agg([
        pl.col('ENFANT').mean().alias('mean'),
        pl.col('ENFANT').std().alias('std'),
        pl.col('ENFANT').min().alias('min'),
        pl.col('ENFANT').quantile(0.25).alias('25%'),
        pl.col('ENFANT').median().alias('50%'),  # Médiane
        pl.col('ENFANT').quantile(0.75).alias('75%'),
        pl.col('ENFANT').max().alias('max'),
        pl.col('ENFANT').sum().alias('sum'),
        pl.col('ENFANT').count().alias('n')
    ])
)
print(result)
```

```
shape: (2, 10)
```

CATEGORIE	mean	std	min	…	75%	max	sum	n
str	f64	f64	i64		f64	i64	i64	u32
EXE	2.451452	2.665344	0	…	4.0	16	7852	3203
M&C	1.846911	2.291155	0	…	3.0	14	4693	2541

De ce tableau, il résulte comme informations suivantes :

- Dans la catégorie EXE, chaque employé a aux alentours de 3 enfants en moyenne, tandis que dans la catégorie M&C la tendance est autour de deux enfants en moyenne.
- Près de 75% d'employés dans la catégorie EXE ne dépasse pas 4 enfants, avec une exception d'au moins une personne qui a 16 enfants.
- Mais si nous prenons la Catégorie M&C, près de 50% d'employé ont moins d'un enfant ; et près de 75% d'agent ne dépense pas 3 enfants. Il y aussi une exception d'au moins un agent qui a 14 enfants.

De cette analyse, on peut donc dire, les employés qui ont un salaire faible, ont tendance a avoir plus d'enfants comparativement à ceux qui ont un salaire assez élevé.

Categorie vs INDEPOUSE

```
# Création de la table de contingence avec group_by et pivot
contingency_table = (
    data_pl_new.group_by(['CATEGORIE', 'INDEPOUSE'])
    .agg(pl.count().alias('count'))
    .pivot(
        values='count',
        index='CATEGORIE',
        columns='INDEPOUSE'
    )
    .fill_null(0)
)

# Calcul des pourcentages par rapport à la somme de chaque ligne dans
Polars
contingency_table_percent = contingency_table.with_columns([
    ((pl.col('0') / (pl.col('0') + pl.col('1'))) *
100).alias('INDEPOUSE_0'),
    ((pl.col('1') / (pl.col('0') + pl.col('1'))) *
100).alias('INDEPOUSE_1')
])
```

```
# Configuration des styles pour le graphique
plt.style.use('ggplot')
plt.rcParams['font.family'] = 'DejaVu Sans'
plt.rcParams['axes.edgecolor'] = '#333F4B'
plt.rcParams['axes.linewidth'] = 0.8
plt.rcParams['xtick.color'] = '#333F4B'
plt.rcParams['ytick.color'] = '#333F4B'
plt.rcParams['text.color'] = '#333F4B'

# Création du graphique avec les pourcentages
contingency_table_percent[['CATEGORIE', 'INDEPOUSE_0',
'INDEPOUSE_1']].to_pandas().plot(kind='barh', stacked=True, figsize=(8,
4), color=['#007ACC', '#FF5733'], alpha=0.85)

# Configuration des axes et des étiquettes
plt.title('Répartition des Catégories selon INDEPOUSE', fontsize=16,
weight='bold', color='#333F4B')
plt.xlabel('Pourcentage', fontsize=14, weight='bold', color='#333F4B')
plt.ylabel('Catégorie', fontsize=14, weight='bold', color='#333F4B')
plt.xticks(fontsize=12)
plt.yticks(fontsize=12)

# Suppression des spines inutiles
ax = plt.gca()
ax.spines['top'].set_visible(False)
ax.spines['right'].set_visible(False)

# Affichage du graphique
plt.tight_layout()
plt.show()
```

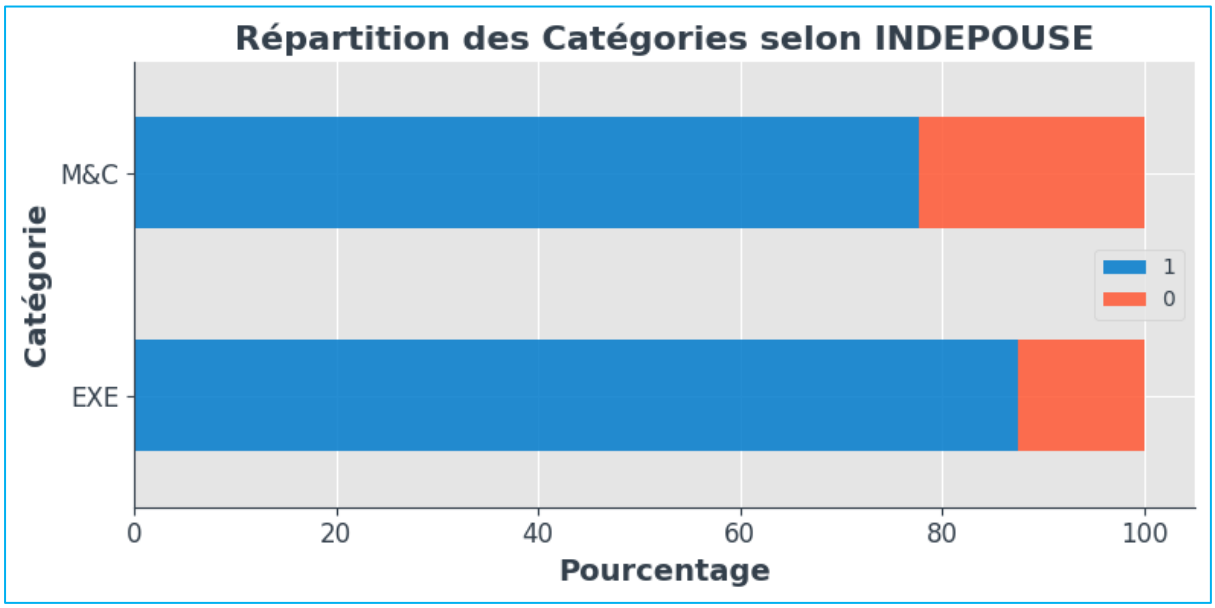

Nous constatons dans chaque catégorie que la proportion des hommes est largement supérieure à celle des femmes. Mais cela est dû à la faible représentativité des femmes par rapport aux hommes au sein de cette société, car les femmes sont moins de 15% dans cette firme.

- **Etude des liaisons et de corrélations**

Sur ce point nous allons essayer de voir le rapprochement qui existe entre différentes variables, car si les variables sont fortement liées cela risquera de créer des problèmes lors de la modélisation. Par exemple le problème de multicolinéarité[1].

1. Cas des variables Quantitatives

Ici nous faire la corrélation des variables quantitatives de Pearson.

```
# Calcul de la matrice de corrélation
corr_matrix = data_pd[['SALAIRE PERS', 'ENFANT', 'TRP', 'LGT', 'SSANTE',
'ENERGIE', 'IFT', 'IDP', 'IPM', 'age_engagement']].corr()

# Masque pour afficher uniquement la moitié supérieure de la matrice
mask = np.triu(np.ones_like(corr_matrix, dtype=bool))

# Création d'une figure
plt.figure(figsize=(12, 10))
sns.set_theme(style="white")

# Création de la heatmap avec un design plus sophistiqué
sns.heatmap(
    corr_matrix,
    mask=mask,  # Application du masque
    annot=True,  # Affiche les valeurs
    fmt=".2f",  # Format des valeurs
    cmap='Spectral',  # Palette de couleurs attrayante
    center=0,  # Centre la palette autour de 0
    cbar_kws={'shrink': 0.75, 'aspect': 20},  # Configuration de la barre
de couleur
    linewidths=0.5,  # Espacement entre les cellules
    linecolor='gray',  # Couleur des lignes
    square=True  # Format carré pour chaque cellule
)

# Personnalisation des axes et du titre
plt.title("Corrélations des variables quantitatives", fontsize=18,
weight='bold', color='#333F4B')
```

[1] La **multicolinéarité** est un phénomène statistique qui survient lorsque deux ou plusieurs variables indépendantes dans un modèle de régression sont fortement corrélées. Cela signifie qu'il existe une forte relation linéaire entre ces variables, ce qui complique l'estimation des coefficients de la régression.
Mathématiquement, c'est si l'une au moins des variables peut s'écrire comme combinaison linéaire des autres variables.

```
plt.xticks(rotation=45, ha='right', fontsize=12, weight='bold')
plt.yticks(rotation=0, fontsize=12, weight='bold')
plt.xlabel('Variables', fontsize=14, weight='bold', color='#333F4B')
plt.ylabel('Variables', fontsize=14, weight='bold', color='#333F4B')

# Affichage du graphique
plt.tight_layout()
plt.show()
```

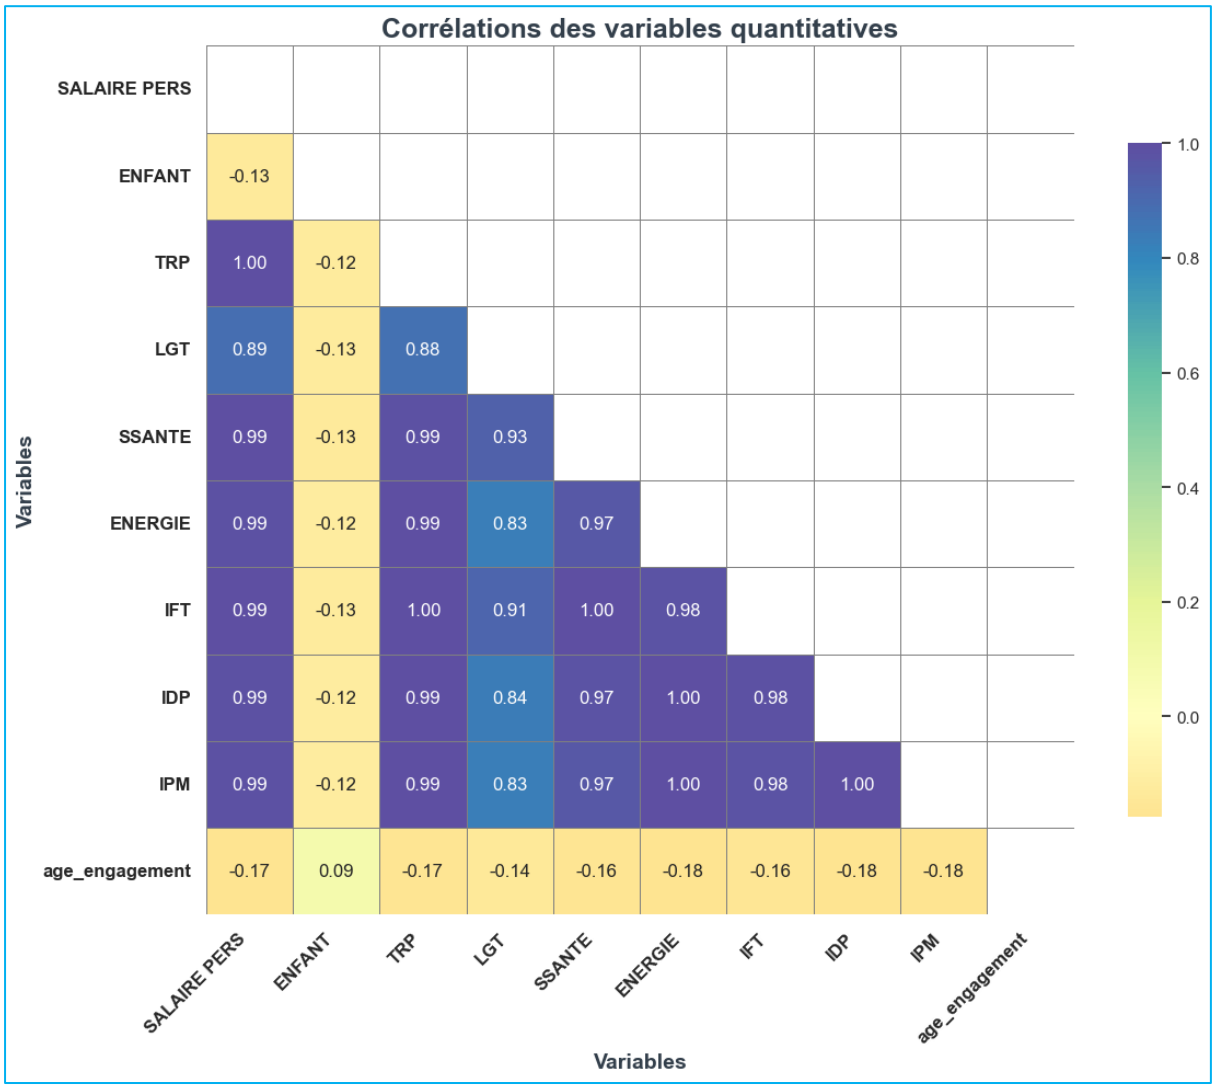

Nous remarquons des très fortes corrélations dans le sens positif entre différentes variables, ceci signifie que lorsque la valeur d'une variable augmente, la valeur de l'autre augmente **exactement** de la même manière, de façon proportionnelle.

Or, ces corrélations très fortes ou parfaites ne sont pas bien pour la modélisation, ça créera des problèmes de multicolinéarité.

D'où, certaines variables ne doivent pas figurer dans la modélisation (cfr : les variables en bleu sur le graphique).

2. Cas des variables Qualitatives

La corrélation dans le cadre des variables qualitative est appelée liaison, mais elle ne peut pas être calculée de la même manière que pour les variables quantitatives, car les méthodes classiques comme le **coefficient de corrélation de Pearson** ne s'appliquent qu'aux données numériques. Cependant, il existe d'autres méthodes adaptées pour mesurer l'association ou la dépendance entre des variables qualitatives :

1. Coefficient de corrélation de Cramér (Cramér's V)

- Il est utilisé pour mesurer la force de l'association entre deux variables catégorielles.
- Calculé à partir du **test du Chi-carré**, Cramér's V varie entre 0 (aucune association) et 1 (association parfaite).
- Il convient lorsque les variables ont plus de deux catégories.

2. Coefficient Phi (Φ)

- Utilisé pour mesurer l'association entre deux variables binaires (ayant chacune deux catégories).
- Il s'agit d'un cas particulier de Cramér's V lorsque le tableau de contingence est de dimension 2x2.

3. Test du Chi-carré d'indépendance

- Permet de vérifier si deux variables qualitatives sont statistiquement indépendantes ou s'il existe une association entre elles.
- Bien qu'il ne donne pas directement un coefficient de corrélation, il permet de déterminer si une relation significative existe entre les variables.

4. Indice de corrélation de Theil (Theil's U ou l'entropie conditionnelle)

- Utile pour mesurer la dépendance asymétrique entre deux variables catégorielles.
- Contrairement aux méthodes ci-dessus, cet indice peut être asymétrique (la relation d'une variable à l'autre peut ne pas être réciproque).

5. Corrélation de Kendall's Tau pour les variables ordinales

- Si vos variables qualitatives sont ordinales (elles ont un ordre mais ne sont pas numériques), vous pouvez utiliser la **corrélation de Kendall's Tau** pour mesurer la force de l'association ordonnée.

6. Tableaux de contingence

- En plus des coefficients, il est courant de visualiser les associations entre les variables qualitatives à l'aide de **tableaux croisés** (ou tableaux de contingence). Ces tableaux

montrent les fréquences de chaque combinaison possible de catégories entre les variables.

```
# Étape 1: Créer le tableau de contingence
contingency_table = pd.crosstab(index=[data_pd['CATEGORIE'],
data_pd['SEXE']], columns=data_pd['INDEPOUSE'])

# Étape 2: Afficher le tableau de contingence avec un design amélioré
print(Fore.MAGENTA + Style.BRIGHT + "### Tableau de Contingence ###")
print(Style.RESET_ALL)

# Format de tableau plus esthétique avec bordures et alignement
print(Fore.CYAN + tabulate(contingency_table, headers='keys',
tablefmt='fancy_grid', showindex=True, stralign="center"))
print(Style.RESET_ALL)
print(Fore.MAGENTA + Style.BRIGHT + "-"*40 + Style.RESET_ALL)  #
Séparateur visuel

# Étape 3: Définir la fonction pour calculer le Cramér's V
def cramers_v(confusion_matrix):
    """
    Calcule la statistique de Cramér's V pour mesurer l'association entre
les variables catégorielles.

    :param confusion_matrix: Un tableau de contingence
    :return: La valeur de Cramér's V (entre 0 et 1)
    """
    # Statistique du test du chi-carré et nombre total d'observations
    chi2_statistic = ss.chi2_contingency(confusion_matrix)[0]
    total_obs = confusion_matrix.sum().sum()

    # Calcul du phi-squared
    phi2 = chi2_statistic / total_obs

    # Nombre de lignes et de colonnes dans le tableau de contingence
    rows, cols = confusion_matrix.shape

    # Appliquer les corrections pour phi-squared
    phi2_corrected = max(0, phi2 - ((cols - 1) * (rows - 1)) / (total_obs
- 1))
    rows_corr = rows - ((rows - 1) ** 2) / (total_obs - 1)
    cols_corr = cols - ((cols - 1) ** 2) / (total_obs - 1)

    # Retourner la racine carrée de la valeur corrigée de phi-squared
    return np.sqrt(phi2_corrected / min((cols_corr - 1), (rows_corr -
1)))

# Étape 4: Calcul de Cramér's V
cramers_v_value = cramers_v(contingency_table)

# Étape 5: Affichage du résultat avec un design plus moderne
```

```
print(Fore.GREEN + Style.BRIGHT + "\n### Résultat Cramér's V ###")
print(Fore.GREEN + "-"*40)  # Ligne de séparation
print(f"{Style.BRIGHT}Cramér's V:
{cramers_v_value:.4f}{Style.RESET_ALL}")
print(Fore.GREEN + "-"*40)  # Ligne de séparation

# Interprétation de la valeur de Cramér's V
if cramers_v_value < 0.1:
    print(Fore.YELLOW + Style.BRIGHT + "Faible association entre les
variables." + Style.RESET_ALL)
elif cramers_v_value < 0.3:
    print(Fore.CYAN + Style.BRIGHT + "Association modérée entre les
variables." + Style.RESET_ALL)
else:
    print(Fore.RED + Style.BRIGHT + "Association forte entre les
variables." + Style.RESET_ALL)

# Réinitialiser les styles à la fin
print(Fore.MAGENTA + "-"*40 + Style.RESET_ALL)  # Séparateur final
print(Style.RESET_ALL)
```

```
...  ### Tableau de Contingence ###
```

	0	1
('EXE', 'F')	187	3
('EXE', 'M')	190	2635
('M&C', 'F')	425	7
('M&C', 'M')	138	1949

```
----------------------------------------

### Résultat Cramér's V ###
----------------------------------------
Cramér's V: 0.7712
----------------------------------------
Association forte entre les variables.
----------------------------------------
```

Nous remarquons une association forte entre la catégorie, le sexe et l'INDEPOUSE ; la force de cette association est de 77%.

Modélisation

Pour l'instant certaines variables sont à exclure à cause des incohérences sur ces variables. Parmi ces variables, nous excluons : 'DERNIER AVACEMENT EN GRADE', 'COTATION', 'DATENAISSA', 'DATEENGAGE', 'tranche_age_engagement', 'GRADE','ETATCIVIL'

shape: (5_744, 14)

CATEGORIE	SALAIRE PERS	CITE	SEXE	…	IFT	IDP	IPM	age_engagement
---	---	---	---		---	---	---	---
str	f64	str	str		f64	f64	i64	i32
M&C	47865.44225	06	M	…	97837.51	126115.18	348500	18
M&C	47652.18334	05	M	…	97837.51	126115.18	348500	26
M&C	47348.71096	06	M	…	97837.51	126115.18	348500	27
M&C	47115.68266	01	M	…	97837.51	126115.18	348500	24
M&C	47344.56758	02	M	…	97837.51	126115.18	348500	24
…	…	…	…	…	…	…	…	…
EXE	4920.44077	10	M	…	67568.84	46635.93	342500	33
EXE	4920.44077	10	M	…	67568.84	46635.93	342500	23
EXE	4920.44077	10	M	…	67568.84	46635.93	342500	26
EXE	4913.62077	10	M	…	67278.84	46413.51	342500	35
EXE	4913.62077	10	M	…	67278.84	46413.51	342500	32

```
#### Sélection des variables pour le modèle
data_model = data_pl_new.select(
    pl.all().exclude(['DERNIER AVACEMENT EN GRADE', 'COTATION',
'DATENAISSA', 'DATEENGAGE', 'tranche_age_engagement', 'GRADE','ETATCIVIL'
])
)

# Convertir les données Polars en DataFrame Pandas pour la manipulation
df = data_model.to_pandas()

# Identifier les colonnes catégorielles
colonnes_categoricielles = ["CITE", "SEXE", "INDEPOUSE"]

# Appliquer un encodage LabelEncoder sur ces colonnes
label_encoders = {}
for col in colonnes_categoricielles:
    le = LabelEncoder()
    df[col] = le.fit_transform(df[col])
    label_encoders[col] = le

# Encodage de la variable cible
df["CATEGORIE"] = LabelEncoder().fit_transform(df["CATEGORIE"])

# Séparer les données en X et y
X = df.drop(columns=["CATEGORIE"])
y = df["CATEGORIE"]

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42) # 80% des données sont utilisées pour l'entraînement
```

```python
# Initialiser et entraîner le modèle de régression logistique
model = LogisticRegression(max_iter=1000)
model.fit(X_train, y_train)

# Prédictions et évaluation
y_pred = model.predict(X_test)
accuracy = accuracy_score(y_test, y_pred)
report = classification_report(y_test, y_pred)

print(f"Accuracy: {accuracy}")
print("Classification Report:")
print(report)
```

```
Accuracy: 1.0
Classification Report:
              precision    recall  f1-score   support

           0       1.00      1.00      1.00       632
           1       1.00      1.00      1.00       517

    accuracy                           1.00      1149
   macro avg       1.00      1.00      1.00      1149
weighted avg       1.00      1.00      1.00      1149
```

Les résultats de ce modèle paraissent meilleurs alors qu'il y a un problème, soulevé lors de l'analyse bivariées.

Pour mieux voir, les résultats nous utilisons la librairie statmodels :

```
Warning: Maximum number of iterations has been exceeded.
         Current function value: 0.000000
         Iterations: 35
                           Logit Regression Results
==============================================================================
Dep. Variable:              CATEGORIE   No. Observations:                 4595
Model:                          Logit   Df Residuals:                     4582
Method:                           MLE   Df Model:                           12
Date:                Sat, 02 Nov 2024   Pseudo R-squ.:                  1.000
Time:                        13:40:12   Log-Likelihood:           -1.0203e-12
converged:                      False   LL-Null:                      -3152.4
Covariance Type:            nonrobust   LLR p-value:                    0.000
==============================================================================
                 coef    std err          z      P>|z|      [0.025      0.975]
------------------------------------------------------------------------------
SALAIRE PERS  1.884e-06    621.986   3.03e-09      1.000   -1219.070    1219.070
CITE          6.417e-05   2.24e+05   2.86e-10      1.000    -4.4e+05     4.4e+05
SEXE          3.088e-07   4.18e+06   7.39e-14      1.000   -8.19e+06    8.19e+06
INDEPOUSE    -6.063e-07    3.1e+06  -1.95e-13      1.000   -6.08e+06    6.08e+06
ENFANT       -1.028e-05   4.34e+05  -2.37e-11      1.000   -8.51e+05    8.51e+05
TRP           8.947e-06   1577.439   5.67e-09      1.000   -3091.723    3091.723
LGT          -1.299e-06    136.398  -9.52e-09      1.000    -267.336     267.336
SSANTE       -4.101e-06    232.712  -1.76e-08      1.000    -456.108     456.108
ENERGIE          0.0101   6.05e+04   1.67e-07      1.000   -1.19e+05    1.19e+05
IFT          -3.695e-05   2372.571  -1.56e-08      1.000   -4650.154    4650.154
```

Avec ces résultats, aucune variable n'est significative. Or ce problème a été décelé au niveau de l'analyse des corrélations.

Pour ça, on doit identifier les variables à problèmes à l'aide de l'étude de la multicolinéarité.

Etude de la multicolinéarité

```
# VIF pour chaque variable
vif_data = pd.DataFrame()
vif_data["feature"] = X.columns
vif_data["VIF"] = [variance_inflation_factor(X.values, i) for i in
range(X.shape[1])]

print(vif_data)
```

```
           feature            VIF
0     SALAIRE PERS     221.698094
1             CITE       1.078873
2             SEXE       1.746441
3        INDEPOUSE       1.702281
4           ENFANT       1.060799
5              TRP    2472.915463
6              LGT      20.045121
7           SSANTE     472.829447
8          ENERGIE  313247.777713
9              IFT    1813.738318
10             IDP   39994.592023
11             IPM   47944.429271
12  age_engagement       1.087536
```

Les variables à éliminer sont celles la valeur du VIF excède 10 ; ce qui confirme notre présomption au niveau de la corrélation.

La meilleure stratégie est d'éliminer une variable après une autre et voir le comportement du modèle. Mais sur base de notre hypothèse sur la corrélation certaines variables ne doivent pas figurer ensemble dans la modélisation. Entre autres : Salaire pers, TRP, LGT, SSANTE, ENERGIE, IFT, IDP, IPM.

Après plusieurs tests de suppression des variables, celles retenues sont :

shape: (5_744, 6)

CATEGORIE	CITE	SEXE	INDEPOUSE	ENFANT	age_engagement
str	str	str	str	i64	i32
M&C	06	M	1	0	18
M&C	05	M	0	0	26
M&C	06	M	1	0	27
M&C	01	M	1	0	24
M&C	02	M	1	1	24
…	…	…	…	…	…
EXE	10	M	null	0	33
EXE	10	M	null	0	23
EXE	10	M	null	0	26
EXE	10	M	null	0	35
EXE	10	M	null	0	32

```
# Convertir les données Polars en DataFrame Pandas pour la manipulation
df = data_model.to_pandas()

# Identifier les colonnes catégorielles
colonnes_categoricielles = ["CITE", "INDEPOUSE", 'SEXE']

# Appliquer un encodage LabelEncoder sur ces colonnes
label_encoders = {}
for col in colonnes_categoricielles:
    le = LabelEncoder()
    df[col] = le.fit_transform(df[col])
    label_encoders[col] = le

# Encodage de la variable cible
df["CATEGORIE"] = LabelEncoder().fit_transform(df["CATEGORIE"])

# Séparer les données en X et y
X = df.drop(columns=["CATEGORIE"])
y = df["CATEGORIE"]


X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42)
```

```python
# Initialiser et entraîner le modèle de régression logistique
model = LogisticRegression(max_iter=1000)
model.fit(X_train, y_train)

# Prédictions et évaluation
y_pred = model.predict(X_test)
accuracy = accuracy_score(y_test, y_pred)
report = classification_report(y_test, y_pred)

print(f"Accuracy: {accuracy}")
print("Classification Report:")
print(report)
```

```
Accuracy: 0.6362053959965187
Classification Report:
              precision    recall  f1-score   support

           0       0.63      0.80      0.71       632
           1       0.64      0.44      0.52       517

    accuracy                           0.64      1149
   macro avg       0.64      0.62      0.61      1149
weighted avg       0.64      0.64      0.62      1149
```

Pour mieux interpréter les résultats, nous utilisons la librairie statmodels :

```python
model = sm.Logit(y_train, X_train)
result = model.fit(maxiter=1000)

# Afficher le résumé du modèle
print(result.summary())
```

```
Optimization terminated successfully.
         Current function value: 0.662517
         Iterations 5
                           Logit Regression Results
==============================================================================
Dep. Variable:              CATEGORIE   No. Observations:                 4595
Model:                          Logit   Df Residuals:                     4590
Method:                           MLE   Df Model:                            4
Date:                Sat, 02 Nov 2024   Pseudo R-squ.:                0.03429
Time:                        14:45:34   Log-Likelihood:                -3044.3
converged:                       True   LL-Null:                       -3152.4
Covariance Type:            nonrobust   LLR p-value:                 1.219e-45
==============================================================================
                 coef    std err          z      P>|z|      [0.025      0.975]
------------------------------------------------------------------------------
CITE           -0.0592      0.007     -8.939      0.000      -0.072      -0.046
SEXE            0.1462      0.112      1.300      0.194      -0.074       0.367
INDEPOUSE      -0.4444      0.091     -4.881      0.000      -0.623      -0.266
ENFANT         -0.0894      0.013     -6.930      0.000      -0.115      -0.064
age_engagement  0.0140      0.003      4.672      0.000       0.008       0.020
==============================================================================
```

On sait maintenant voir que la modèle a une précision de 66% sur les données d'entraînement et une précision de 63% celles de test.

En plus, tous les paramètres sont significatifs pour l'explication du modèle à un niveau de confiance de 95%.

Recommandations

Ces analyses sont faites sur base de la nature des variables, d'autres pistes de recherche sont aussi viables, entre autres :

- Exploration des autres modèles de Machine learning (Analyse discriminante, K-means, …)
- Ajout d'une régularisation : cas de la régression logistique avec régularisation (comme Ridge ou Lasso)
- Réaliser l'AFDM (Analyse Factorielle Des Données Mixtes), afin de détecter les variables les plus corrélées avec la catégorie de l'employé, puis les éliminer.
- Etc.

Code source du travail